Explorando e Visualizando Dados

1. Importação de Dados no SAS Studio com a Proc Import

1.1 Objetivo

Este exercício tem como objetivo capacitar o aluno a realizar uma **análise exploratória de dados** utilizando ferramentas do SAS, com foco na compreensão da estrutura do conjunto de dados, identificação de padrões, valores extremos e possíveis inconsistências. Por meio do uso de procedures como **PROC PRINT, PROC MEANS, PROC FREQ e PROC UNIVARIATE**, o aluno será orientado a gerar estatísticas descritivas, tabelas de frequência e gráficos interativos, promovendo uma leitura visual e estatística dos dados que apoie interpretações iniciais e formule hipóteses analíticas para etapas posteriores de modelagem ou tomada de decisão.

1.2 Utilização das Bases de Dados

- Acesse o link https://drive.google.com/drive/folders/1d9Fvz7EkYVXDpkS3W0CK376tab-062Cy?usp=sharing
- Acesse a pasta "**Bases de Dados**"
- Selecione o arquivo "**sus_prod_ambulatorial.csv**" e "**ENEM_2023_AMOSTRA_PERFEITA.xlsx**" e faça o download para o seu computador.
- Importe estes dois arquivos para o **SAS Studio**. na importação do arquivo **.CSV** configure a **Proc Import** com os seguintes parâmetros.
    - **Filename**: Identifique o endereço físico do seu arquivo
    - **encoding**='windows-1252'
    - out= **sus_prod_ambulatorial**
    - dbms=**csv**
    - replace**;**
    - delimiter=';'**;**
    - guessingrows=MAX**;**

2. Explorando e Visualizando Dados

2.1 Agora, vamos explorar o arquivo "ENEM_2023_AMOSTRA_PERFEITA".

2.1.1 Uso da Proc Contents

- Faça um relatório para **conhecer o arquivo de dados** e as **características de suas variáveis**

2.1.2 Uso da Proc Print (1)

- Faça **um relatório** contendo as seguintes variáveis: Numero_Inscricao, Faixa_Etaria, Idade, NOTA_CIENCIAS_DA_NATUREZA, NOTA_CIENCIAS_HUMANAS, NOTA_LINGUAGENS_E_CODIGOS, NOTA_MATEMATICA e NOTA_REDACAO
- Selecione apenas **500 observações** (candidatos) para o seu relatório.
- Coloque o seguinte título no relatório: '**Relação de candidatos do ENEM 2023 e suas notas**".
- Coloque o seguinte rodapé no relatório: '**Fonte: MEC/Inep**".

2.1.3 Uso da Proc Print (2)

- Refaça o relatório anterior, porém, .ordene a base de dados pelas variáveis Sigla_UF_Prova (ascendente) e NOTA_MATEMATICA (descendente).
- Utilize a instrução BY e/ou PageBy

2.1.4 Uso da Proc Means (1)

- Faça **um relatório** contendo uma análise estatística descritiva das variáveis , NOTA_CIENCIAS_HUMANAS e NOTA_LINGUAGENS_E_CODIGOS.
- Calcule as seguintes estatísticas:
  - ✓ Média aritmética (Mean)
  - ✓ Desvio Padrão (Std Dev)
  - ✓ Valor Mínimo (Minimum)
  - ✓ Valor Máximo (Maximum)
  - ✓ Mediana (Median)
  - ✓ Número de observações (N)
  - ✓ Coeficiente de Variação(Coeff of Variation)
  - ✓ Primeiro Quartil(Lower Quartile)

- ✓ Terceiro Quartil (Upper Quartile)

- Coloque o seguinte título no relatório: '**Análise das notas de Ciências Humanas e Linguagens e Códigos do Candidatos ao ENEM 2023**".
- Coloque o seguinte rodapé no relatório: '**Fonte: MEC/Inep**".

2.1.5 Uso da Proc Means (2)

- Refaça o relatório anterior, porém, .calcule estas estatísticas por:
  - ✓ Sexo
  - ✓ Cor_Raca
  - ✓ Sigla_UF_Prova
- Utilize a instrução **BY**
- Grave em uma nova **SAS Table** os resultados das estatísticas por **Sigla_UF_Prova.** Coloque os nomes das estatísticas calculadas em português, por exemplo Media_Aritmetica, Mediana, etc.
- Imprima **(Proc Print)** o arquivo gravado com as estatísticas por **Sigla_UF_Prova**

2.1.6 Uso da Proc Univariate (1)

- Faça **um relatório** contendo uma análise estatística descritiva das variáveis NOTA_MATEMATICA e NOTA_MEDIA. **Acrescente nesta análise o HISTOGRAMA** dessas variáveis.
- Coloque o seguinte título no relatório: '**Análise das notas de Matemática e Nota Médicas das 5 Provas do Candidatos ao ENEM 2023**".
- Coloque o seguinte rodapé no relatório: '**Fonte: MEC/Inep**".

2.1.7 Uso da Proc Univariate (2)

- Refaça o relatório anterior, porém, .calcule estas estatísticas por:
  - ✓ Sexo
  - ✓ Cor_Raca
  - ✓ Sigla_UF_Prova
  - ✓ Sigla_UF_Prova, Sexo, Cor_Raca
- Utilize a instrução **BY**
- Grave em uma nova **SAS Table** os resultados das estatísticas por **Sigla_UF_Prova, Sexo e Cor_Raca.** Coloque os nomes das

estatísticas calculadas em português, por exemplo Media_Aritmetica, Mediana, etc.

- Imprima **(Proc Print)** o arquivo gravado com as estatísticas por **Sigla_UF_Prova, Sexo e Cor_Raca**

2.1.8 Uso da Proc Univariate (3)

- Refaça o relatório anterior definido em **2.1.6 -Proc Univariate (1)**, porém, .acrescente os gráficos gerados pelas opções **Histogram** (Histograma)**, CDFPLOT (**Cumulative Distribution Function**), PPPLOT (**probabilidade-probabilidade (também conhecido como gráfico P-P ou gráfico de porcentagem)), e **PROBPLOT** (gráfico usado para avaliar se um conjunto de dados segue uma distribuição estatística específica, como a distribuição normal).

2.1.9 Uso da Proc Freq (1)

- Faça **um relatório** contendo a **Distribuição de Frequência** das variáveis Sexo, Faixa_Etaria, Cor_Raca e Tipo_Escola.
- Coloque o seguinte título no relatório: '**Distribuição de Frequência das Variáveis Sexo, Faixa Etária, Cor e Raça e Tipo de Escola dos Candidatos ao ENEM 2023**".
- Coloque o seguinte rodapé no relatório: '**Fonte: MEC/Inep**".

2.1.10 Uso da Proc Freq (2)

- Refaça a análise anterior, acrescentando os gráficos de **Frequência e Frequência Acumulada**.

2.1.11 Uso da Proc Freq (3)

- Refaça a análise anterior do item **2.1.9 - Proc Freq (1)**, porém, .ordene a base de dados pelas variáveis Sigla_UF_Prova (ascendente)
- Utilize a instrução **BY**.

2.1.12 Uso da Proc Freq (4)

- Faça **um relatório** contendo a **Distribuição de Frequência** Cruzada das variáveis Sexo e Cor_Raca (**Sexo * Cor_Raca**).

2.2 Agora, vamos explorar o arquivo "SUS_Prod_Ambulatorial".

2.2.1 Uso da Proc Contents

- Faça um relatório para **conhecer o arquivo de dados** e as **características de suas variáveis**

2.2.2 Aplique o comando Label e gere uma nova versão do arquivo com a descrição de cada variável.

2.2.3 Uso da Proc Means (1)

- Faça **um relatório** contendo uma análise estatística descritiva das variáveis **QTD_Total** e **VL_Total**.
- Calcule as seguintes estatísticas:
  - ✓ Soma das Variáveis (SUM)
  - ✓ Número de observações (N)
  - ✓ Média aritmética (Mean)
  - ✓ Desvio Padrão (Std Dev)
  - ✓ Valor Mínimo (Minimum)
  - ✓ Valor Máximo (Maximum)
  - ✓ Mediana (Median)
  - ✓ Primeiro Quartil(Lower Quartile)
  - ✓ Terceiro Quartil (Upper Quartile)
- Coloque o seguinte título no relatório: '**Análise dos Procedimentos Ambulatoriais do SUS**".
- Coloque o seguinte rodapé no relatório: '**Fonte: MS/SUS/Datasus**".

2.2.4 Uso da Proc Means (2)

- Refaça a Análise Anterior, agrupada (**By**) pela variável Ano_Produção_Ambulatoria e Classificada (**Class**) pela variável
- Calcule as seguintes estatísticas:
  - ✓ **Soma das Variáveis** (SUM)
  - ✓ Número de observações (N)
  - ✓ Média aritmética (Mean)
  - ✓ Desvio Padrão (Std Dev)
  - ✓ Valor Mínimo (Minimum)
  - ✓ Valor Máximo (Maximum)

- ✓ Mediana (Median)
- ✓ Primeiro Quartil(Lower Quartile)
- ✓ Terceiro Quartil (Upper Quartile)

- Coloque o seguinte título no relatório: '**Análise dos Procedimentos Ambulatoriais do SUS**".
- Coloque o seguinte rodapé no relatório: '**Fonte: MS/SUS/Datasus**".