Explorando e Visualizando Dados com SAS

1. Introdução

O **Exame Nacional do Ensino Médio (ENEM)** tem como principal objetivo avaliar o desempenho escolar dos estudantes ao final da educação básica, mais especificamente ao término do ensino médio. Criado em 1998 pelo Ministério da Educação (MEC), o **ENEM** tornou-se, ao longo dos anos, uma das principais ferramentas para medir o domínio das competências e habilidades desenvolvidas pelos alunos durante a trajetória escolar. Mais do que testar a memorização de conteúdos, o exame valoriza a capacidade de interpretar textos, analisar informações, resolver problemas, estabelecer relações entre áreas do conhecimento e aplicar esse saber em contextos da vida cotidiana.

Além da avaliação educacional, o ENEM cumpre um papel estratégico de inclusão social e democratização do acesso ao ensino superior. Por meio de seus resultados, milhões de estudantes podem concorrer a vagas em universidades públicas através do *Sistema de Seleção Unificada (SISU)*, obter bolsas em instituições privadas com o *Programa Universidade para Todos (PROUNI)* ou pleitear financiamento estudantil via o *Fundo de Financiamento Estudantil (FIES)*. Também é crescente o número de instituições internacionais, especialmente em Portugal, que aceitam o ENEM como parte do processo seletivo de estudantes brasileiros.

Outro objetivo relevante do exame é subsidiar políticas públicas voltadas para a melhoria da qualidade da educação no país. Os dados coletados nas provas permitem que gestores educacionais avaliem o desempenho por região, escola ou rede de ensino, identificando fragilidades e orientando ações de correção. Embora o ENEM, até o concurso de 2024 não servia mais como certificação do ensino médio ele ainda cumpria um papel de inclusão, uma vez que ampliava as oportunidades para jovens e adultos em diferentes contextos sociais.

A partir do *ENEM 2025 poderá ser usado como certificado de conclusão do Ensino Médio* para participantes maiores de 18 anos que não concluíram essa etapa da educação básica. Essa medida, que havia sido descontinuada em 2017, foi retomada pelo Ministério da Educação (MEC) e visa oferecer uma nova alternativa para a obtenção do diploma.

Para obter o certificado, os participantes do ENEM 2025 devem atingir a pontuação mínima exigida em cada área do conhecimento e na redação, conforme estabelecido pelo MEC. Além disso, é necessário ter 18 anos completos até o primeiro dia de aplicação das provas, conforme o edital do exame.

Por fim, o ENEM também estimula uma abordagem pedagógica mais crítica, reflexiva e interdisciplinar, alinhada à Base Nacional Comum Curricular (BNCC). Ao enfatizar competências como argumentação, resolução de problemas, leitura crítica e pensamento científico, o exame contribui para uma formação mais ampla, preparando os estudantes não apenas para o ingresso na universidade, mas também

para o exercício da cidadania e para os desafios do mundo do trabalho e da vida em sociedade.

2. Objetivos do exercício

Este exercício tem como objetivo capacitar o aluno a realizar uma **análise exploratória de dados** utilizando ferramentas do **SAS**, com foco na compreensão da estrutura do conjunto de dados, identificação de padrões, valores extremos e possíveis inconsistências. Por meio do uso de procedures como **PROC PRINT, PROC MEANS, PROC FREQ e PROC UNIVARIATE**, o aluno será orientado a gerar estatísticas descritivas, tabelas de frequência e gráficos, promovendo uma leitura visual e estatística dos dados que apoie interpretações iniciais e formule hipóteses analíticas para etapas posteriores de modelagem ou tomada de decisão.

3. O Processo de Programação SAS

O **processo de programação em SAS** é o núcleo da manipulação, transformação e análise de dados dentro do ecossistema da plataforma. Diante da crescente complexidade e volume das informações, torna-se impossível compreender dados sem ferramentas que permitam organizar, resumir e derivar significados a partir de números e textos. A linguagem de programação Base SAS cumpre esse papel central, permitindo ao usuário estruturar instruções claras para importar, limpar, transformar e analisar conjuntos de dados de forma robusta e escalável.

Mesmo com a variedade de interfaces gráficas e soluções modulares oferecidas pelo SAS — como Visual Analytics, Enterprise Guide, ou soluções específicas para setores — a linguagem Base SAS está sempre presente como componente fundamental. Aprender a escrever código em SAS significa adquirir controle total sobre as etapas do processamento de dados: da leitura e combinação de múltiplas fontes até a aplicação de estatísticas, modelagens e geração de relatórios. Por isso, dominar o processo de programação em SAS é essencial para quem busca autonomia analítica e precisão na tomada de decisões baseada em dados.

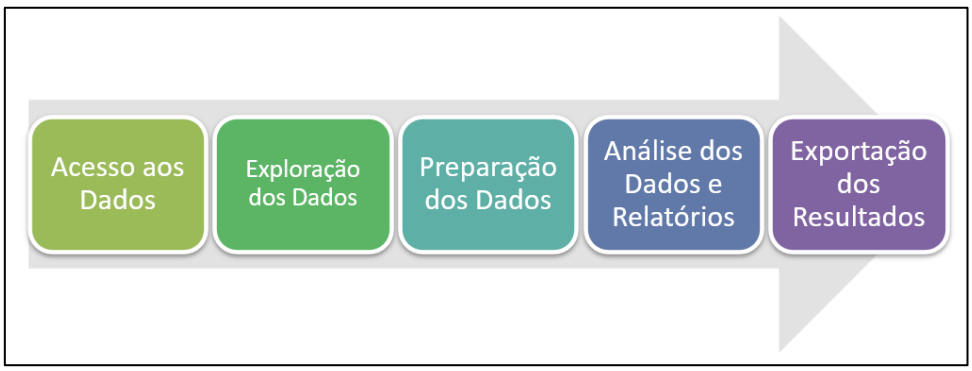


Figura 1: O processo de programação SAS

4. Acesso aos Dados

O **acesso aos dados no SAS** é flexível e poderoso, permitindo a leitura de múltiplas fontes — como arquivos locais, bancos de dados relacionais, planilhas e dados em nuvem — de forma integrada e segura.

4.1 Importação de Dados no SAS Studio com a Proc Import (Programa 01)

- Nome o programa:
  - ✓ <nome completo>_pgm01.sas
  - ✓ **Exemplo**: **sergio_da_costa_cortes_pgm01.sas**
- Acesse o link https://drive.google.com/drive/folders/1d9Fvz7EkYVXDpkS3W0CK376tab-062Cy?usp=sharing
- Acesse a pasta "**Bases de Dados**"
- Selecione os arquivos "**Enem_2024_Amostra_Perfeita.xlsx**", "**SUS_PROD_AMB_2024_2025.csv**" e faça o download para o seu computador.
- Crie a pasta **Dados_04** e faça o Upload dos dois arquivos para esta pasta
- Crie a Library **Dados_04**[1]**,** tendo como a pasta **Dados_04.**
- Importe estes dois arquivos para o **SAS Studio,** mantendo o mesmo nome dos arquivos. Na importação do arquivo **.CSV** configure a **Proc Import** com os seguintes parâmetros.
  - **Filename**: Identifique o endereço físico do seu arquivo
  - **encoding**='windows-1252'
  - **out**= SUS_PROD_AMB_2024_2025
  - **dbms**=csv
  - **replace**
  - **delimiter**=';'
  - **guessingrows**=MAX;

- Utilizando o arquivo "**09-Atribuição de Labes nas variáveis.sas**", da pasta "Programas Exemplos", também no Google Drive, aplique os Labels na tabela "**SUS_PROD_AMB_2024_2025"**.

[1] Você deve manter o nome da **Library** como **Dados_04**, pois a correção e avaliação dos seus programas finais usarão os dados desta **Library**. Caso contrário seus programas, na fase de correção pelo professor, apresentarão erros.

4.2 Acesso ao Banco de Dados PostgreSQL do projeto "Big Data – IESB" (Programa 02)

- Usando as credenciais a seguir, desenvolva um programa para acesso ao SGBD Relacional com Banco de Dados do Projeto Big Data – IESB:

```
/* ----------------------------------------------------------------------------------------
   Conexão com o SGBD PostgreSQL na Amazon - Projeto "Big Data - IESB"
   ---------------------------------------------------------------------------------------- */
/* ------------------------------------------------
   Criação da Library "DataIESB"
   ------------------------------------------------ */


libname DataIESB postgres
    server='bigdata.dataiesb.com'
    port=5432
    user=data_iesb
    password=iesb
    database=iesb
    schema=public
    access=readonly;
Run;
```

4.3 Descrição das características[2] das SAS Tables

Conheça as características das seguintes **SAS Tables** (dataset SAS)

- **Dados_04.**Enem_2024_Amostra_Perfeita
- **Dados_04.**SUS_PROD_AMB_2024_2025
- **DataIESB**. censo_2022_municipio_sexo_idade
- **DataIESB**.ed_enem_2024_participantes
- **DataIESB**.ed_enem_2024_resultados
- **DataIESB**.municipio
- **DataIESB**.unidade_federacao
- **DataIESB**.regiao
- **DataIESB**.educacao_basica

[2] A **PROC CONTENTS** é uma das procedures mais utilizadas no SAS para obter informações detalhadas sobre a estrutura de um conjunto de dados. Com ela, é possível visualizar a lista de variáveis de um dataset, seus tipos, formatos, posições, rótulos e outras propriedades importantes para a compreensão e exploração inicial dos dados.

5. Explorando e Visualizando Dados

Observação: Todos os seus relatórios devem ter **Cabeçalhos** e/ou **Rodapés** que definam os resultados calculados.

5.1 Agora, vamos explorar o arquivo "censo_2022_municipio_sexo_idade", desenvolvendo um programa para: (Programa 03)

5.1.1 Calcular a população do Brasil.

5.1.2 Calcular a população do Brasil por Região.

5.1.3 Calcular a população do Brasil por Unidade da Federação.

5.1.4 Calcular a população do Brasil por Sexo.

5.1.5 Calcular a população do Brasil por Idade.

1.1.1 Calcular a população do Brasil por Unidade da Federação*Sexo.

1.1.2 Calcular a população do Brasil por Unidade da Federação*Sexo*Idade.

1.1.3 Construir um gráfico, apresentando o total da população do Brasil por Unidade da Federação.

1.1.4 Construir um Mapa do Brasil por Município, sendo a população o tamanho da bola.

1.1.5 Sugira e construa mais 3 relatórios com esta base de dados.

5.2 Agora, vamos explorar o arquivo "Enem_2024_Amostra_Perfeita", desenvolvendo um programa para: (Programa 04)

5.2.1 Faça **a Análise da Distribuição** das variáveis "Nota de Matemática" e "Media das 5 notas". (não use o comando ODS[3]).

5.2.2 Inclua no Histograma a "Curva Normal", a "Estimativa de Densidade" e todas as Estatísticas.

5.3 Agora, vamos explorar o arquivo "ed_enem_2024_participantes", desenvolvendo um programa para: (Programa 05)

5.3.1 Calcule a **Distribuição de Frequência** das Variáveis a seguir, incluindo o gráfico de barras simples e acumulado.

- "Nome da UF onde o candidato fez a prova"
- Faixa Etária
- Sexo
- Cor e Raça

5.3.2 Calcule a **Distribuição de Frequência** Cruzada das Variáveis, **NÃO** inclua os gráficos.

- "Nome da UF onde o candidato fez a prova" por Sexo
- Sexo por Cor e Raça
- Cor e Raça por Faixa Etária

[3] É um sistema do SAS que controla a saída de relatórios e outros resultados gerados por procedimentos SAS e pelo DATA step. (https://documentation.sas.com/doc/en/pgmsascdc/9.4_3.5/odsug/p0hlwd4o1ai379n1qfnwnsbdnnqe.htm)

5.4 Vamos explorar o arquivo "Enem_2024_Amostra_Perfeita", desenvolvendo um programa para: (Programa 06)

5.4.1 Crie um novo **Dataset SAS** selecionando o seguinte filtro nas linhas do *Dataset de entrada* (**Enem_2024_Amostra_Perfeita)**.

- sg_uf_prova = '*UF da sua faculdade*', e (and)
- nota_ch_ciencias_humanas > 600
- Formate a variável **nota_media_5_notas** para uma casa decimal e as demais notas sem casa decimal.
- Calcule a variável "Nota_Media_Exatas", sendo ela calculada pela expressão (Nota de matemática + Nota de ciências da natureza)/2.
- Selecione somente as variáveis "Sigla da uf da prova", "sexo", "Cor e Raça", as "6 notas" e "Nota_Media_Exatas".

5.4.2 Utilizando o **Dataset** de saída faça:

- A distribuição de frequência das variáveis "Sexo" e "Cor e Raça", separadamente.
- A distribuição de *frequência cruzada* entre as variáveis "Sexo" e "Cor e Raça", separadamente.
- Analise a distribuição das variáveis **nota_media_5_notas, Nota_Media_Exatas** e **nota_ch_ciencias_humanas.** Além das estatísticas gere o Histograma da distribuição das variáveis.

6. Trabalhando no SAS Workbench

6.1 Carga e dados e acesso ao projeto Big Data-IESB (Programa 07)

6.1.1 Crie a pasta **Dados** em seu **MyFolder.**

6.1.2 Crie a pasta **Programas** em seu **MyFolder.**

6.1.3 Faça o upload do arquivo "**Enem_2024_Amostra_Perfeita.xlsx**" para a pasta **Dados.**

6.1.4 Crie a Library **Dados_01** referenciando a pasta **Dados**.

6.1.5 Importe o arquivo "**Enem_2024_Amostra_Perfeita.xlsx**" usando a library **Dados_01.**

6.1.6 Execute a **Proc Contents** para o arquivo Importado**.**

6.1.7 Crie a Library **Dataiesb usando estes parâmetros para conexão:**

```
server='bigdata.dataiesb.com'
port=5432
user=data_iesb
password=iesb
database=iesb
schema=public;
```

6.1.8 Execute a **Proc Contents** para as seguintes tabelas do Banco de Dados:

- CENSO_2022_MUNICIPIO_SEXO_IDADE
- DATAIESB.ED_ENEM_2024_RESULTADOS
- DATAIESB.ED_ENEM_2024_RESULTADOS_AMOS_PER
- DATAIESB.ED_ENEM_2024_PARTICIPANTES

6.2 Análise do ENEM 2024 (Programa 08)

6.2.1 Utilizando as tabelas **ED_ENEM_2024_RESULTADOS** e **ED_ENEM_2024_PARTICIPANTES** faça uma **Análise Estatística** desses dados com medidas de resumo e gráficos apropriados. Dê uma visão Brasil, por Unidade da Federação, Sexo, Cor e Raça, etc. Coloque títulos apropriados.

6.3 Análise do ENEM 2024 (Programa 09)

6.3.1 Utilizando as tabelas **ED_ENEM_2024_RESULTADOS** e **ED_ENEM_2024_PARTICIPANTES** crie um novo DATASET SAS, selecionando apenas a unidade da federação do seu curso (SP, RJ, DF, RS, CE, BA, ...).

6.3.2 Faça uma **Análise Estatística** desses dados com medidas de resumo e gráficos apropriados. Dê uma visão do seu estado selecionando as variáveis que você julgue importantes para explicar os resultados do ENEM 2024. Coloque títulos apropriados.

6.4 Análise do ENEM 2024 (Programa 10)

6.4.1 Selecione alguns resultados que você achou interessante e exporte estes resultados para:

a) Para **PDF**

b) Para **Power Point**

c) Para **Word**

d) Para **Excel**

e) Para **CSV** (sugiro um **Proc Print** de 100 observações do arquivo selecionado)

7. Entregas

- Você deverá entregar **10 (dez) programas** como solução deste exercício.
- Todos os programas devem **começar com um comentário contendo o seu nome e a sua instituição de ensino,**
- Nome do arquivo com o programa:
  - ✓ <nome completo>_pgm__.sas
  - ✓ **Exemplo**: **sergio_da_costa_cortes_pgm01.sas**

  Caso você tenha alguma dúvida, fique a vontade para me enviar mensagem (61) 98238-2468
- Data de entrega: **até o dia 3 de agosto de 2025**
- **Link para Upload dos trabalhos:**
  - https://drive.google.com/drive/folders/1VrKEk2PtVTdSE_FTx82ggdKgMrHYha0o?usp=sharing